

Machine Learning

Atividade I - Bank Marketing

Prof. Dr. Antonio Marcos Selmini (antonio.selmini@espm.br)

Orientações

- ✓ Por ser uma atividade em dupla, os alunos devem estar registrados no mesmo grupo de atividade. Se não estiverem, a nota não será lançada. Após o lançamento das notas, não haverá mudança de grupo. Caso você faça sozinho e queira ter o feedback do exercício, você deverá estar alocado em um grupo de atividade.
- ✓ Você deverá entregar o notebook (.ipynb) via github e o relatório com a análise (entrega no Canvas). Detalhes estão no corpo do arquivo.
- ✓ Atividades só serão recebidas via Canvas. Nenhuma atividade será recebida por mensagem ou por email ou mesmo em rede social.
- ✓ Atividades idênticas serão consideradas plágio e toda a atividade será ZERADA.
- ✓ Data limite para entrega 04/10 às 23h59. Após às 23h59 do dia 04/10 você poderá entregar a atividade até o dia 06/10 às 23h59, mas haverá uma penalização de 30% na nota atribuída. Isso deve ficar claro: a partir das 00h do dia 05/10, mesmo que passado 1 segundo apenas haverá penalização de 30%.

1. Objetivo

Aplicar o ciclo completo de um projeto de aprendizado de máquina supervisionado sobre uma base real: análise exploratória, preparação dos dados, treinamento de três classificadores (k-vizinhos mais próximos, Naive Bayes e regressão logística), avaliação com métricas adequadas ao problema e comparação crítica dos resultados. Ao final, a dupla deve ser capaz de justificar, com base em evidências, qual modelo é mais adequado ao problema de negócio e por quê.

2. Contexto e base de dados

A base reúne dados reais de campanhas de telemarketing de um banco português, realizadas entre maio de 2008 e novembro de 2010 (Moro, Cortez e Rita, 2014). Cada linha corresponde a um contato telefônico com um cliente, e o objetivo da campanha era vender um depósito a prazo. A variável-alvo aderiu indica se o cliente contratou o produto.

Um depósito a prazo é um produto de investimento conservador: o cliente aplica um valor no banco e se compromete a mantê-lo por um período determinado (por exemplo, 6, 12 ou 24 meses), recebendo uma taxa de juros fixada na contratação; o resgate antecipado implica perda parcial ou total dos juros. O equivalente mais próximo no Brasil é o CDB (Certificado de Depósito Bancário) com vencimento definido. Para o banco, "vender" esse produto significa convencer o cliente a aplicar, o que garante captação estável para financiar empréstimos; daí o investimento em campanhas de telemarketing.

Vale observar que a campanha ocorreu durante a crise financeira internacional de 2008–2010. Isso explica a presença, na base, de indicadores macroeconômicos (taxa Euribor, índice de confiança do consumidor, entre outros) e o seu forte poder preditivo: em períodos de crise e de juros em queda, a disposição das pessoas para imobilizar dinheiro em renda fixa muda de forma significativa. Esses atributos descrevem o contexto do momento do contato, e não o cliente — uma distinção que a dupla deve considerar ao interpretar os resultados.

É fornecido um único arquivo, **bank_marketing_completo.csv**, com 41.188 registros e 21 colunas. Os nomes de colunas e os valores categóricos foram traduzidos para o português, sem acentos, para facilitar o uso em código.

Coluna	Descrição	Valores / exemplo
idade	Idade do cliente	41
profissao	Ocupação	administrativo, operario, tecnico, servicos, gerencia, aposentado, empreendedor, autonomo, empregado_domestico, desempregado, estudante, desconhecido
estado_civil	Estado civil	casado, solteiro, divorciado, desconhecido
escolaridade	Escolaridade	fundamental_4anos, fundamental_6anos, fundamental_9anos, ensino_medio, curso_profissionalizante, superior, analfabeto, desconhecido
inadimplente	Possui crédito em atraso	nao, sim, desconhecido
financiamento_imobiliario	Possui financiamento imobiliário	nao, sim, desconhecido
emprestimo_pessoal	Possui empréstimo pessoal	nao, sim, desconhecido
meio_contato	Meio do último contato	celular, telefone_fixo
mes	Mês do último contato	mar, abr, mai, jun, jul, ago, set, out, nov, dez
dia_semana	Dia da semana do último contato	seg, ter, qua, qui, sex
duracao_ligacao_seg	Duração do último contato, em segundos	261
contatos_campanha_atual	Número de contatos com o cliente nesta campanha (inclui o último)	1
dias_desde_ultimo_contato	Dias desde o último contato em campanha anterior; 999 indica que nunca foi contatado	999
contatos_anteriores	Número de contatos em campanhas anteriores	0
resultado_campanha_anterior	Resultado da campanha anterior	fracasso, sucesso, inexistente
taxa_variacao_emprego	Indicador macroeconômico: variação trimestral do emprego	1.1
indice_precos_consumidor	Indicador macroeconômico: índice mensal de preços ao consumidor	93.994
indice_confianca_consumidor	Indicador macroeconômico: índice mensal de confiança do consumidor	-36.4
euribor_3m	Indicador macroeconômico: taxa Euribor de 3 meses (diária)	4.857
numero_empregados	Indicador macroeconômico: número de empregados no país (trimestral, em milhares)	5191.0
aderiu	Variável-alvo: o cliente contratou o depósito a prazo	nao, sim

3. O problema de classificação

Trata-se de um problema de classificação binária: prever, a partir dos dados do cliente, do histórico de contatos e do contexto econômico, se o cliente irá aderir ao depósito a prazo. A classe positiva é aderiu = sim.

O modelo deve ser pensado para uso prático pelo banco: a previsão seria feita antes de o operador ligar para o cliente, com a finalidade de priorizar os contatos com maior chance de adesão. Essa condição de uso tem consequências sobre quais atributos podem ou não ser utilizados, e cabe à dupla identificá-las (ver Seção 4.4).

4. Etapas obrigatórias

4.1 Análise exploratória

Apresentar as dimensões da base, os tipos de dados, a distribuição da variável-alvo e ao menos três visualizações que relacionem atributos à adesão. Descrever a qualidade da base e registrar toda característica dos dados que, na avaliação da dupla, exija tratamento antes da modelagem ou influencie a forma de avaliar os modelos.

4.2 Preparação dos dados

Realizar as transformações necessárias para que os dados possam ser utilizados pelos três algoritmos. Toda alteração na base — exclusão de registros ou colunas, imputação, recodificação, criação de atributos, escalonamento — deve ser registrada e justificada no relatório. A preparação deve ser conduzida de forma a não comprometer a validade da avaliação dos modelos.

4.3 Modelagem

Treinar os três classificadores sobre o mesmo conjunto de treino e a mesma preparação de dados:

1. **k-vizinhos mais próximos (k-NN);**
2. **Naive Bayes:** a dupla deve escolher a variante adequada (`GaussianNB`, `BernoulliNB` ou `CategoricalNB`) e justificar a escolha em função do tipo dos atributos. É permitido, e recomendado, comparar duas variantes;
3. **Regressão logística:** além do desempenho, interpretar os cinco coeficientes de maior magnitude.

Escolha de hiperparâmetros. A escolha de hiperparâmetros relevantes — no mínimo o valor de k no k-NN e o parâmetro de regularização C na regressão logística — deve ser justificada por validação cruzada, e não por tentativa e erro sobre o conjunto de teste. Dado o tamanho da base, é permitido realizar essa busca sobre uma amostra estratificada do conjunto de treino, desde que o procedimento seja documentado e o modelo final seja treinado sobre o conjunto de treino completo.

4.4 Cenários de avaliação

Todos os modelos devem ser avaliados em dois cenários:

- **Cenário principal:** apenas com os atributos que estariam disponíveis no momento em que o banco decide quais clientes contatar. A dupla deve identificar quais atributos não atendem a essa condição, justificar a exclusão e explicar o que aconteceria se fossem mantidos.
- **Cenário completo:** com todos os atributos da base, para fins de comparação.

O relatório deve comparar os resultados dos dois cenários e discutir por que eventuais diferenças de desempenho não significam que o cenário completo seja melhor para uso prático.

4.5 Avaliação

Para cada modelo e cenário, calcular sobre o conjunto de teste: acurácia; precisão, recall e F1 (por classe); e matriz de confusão, com visualização. A dupla deve indicar qual dessas métricas é a mais adequada para

ESPM | ESPM | ESPM | ESPM | ESPM | ESPM | ESPM | ESPM | ESPM | ESPM | ESPM | ESPM |

Para garantir reprodutibilidade e comparabilidade entre as duplas, reservar 30% dos dados para teste e fixar `random_state=42` em todas as operações que envolvam aleatoriedade.

5.1 Notebook (.ipynb)

- ## 5.2 Relatório técnico (.docx ou .pdf)

1. **Introdução:** descrição do problema de negócio, da base e do objetivo.
2. **Análise exploratória:** principais achados, com as visualizações selecionadas.
3. **Preparação dos dados:** todas as alterações realizadas na base e suas justificativas.
4. **Modelagem:** configuração final de cada modelo e critérios de escolha dos hiperparâmetros.
5. **Resultados:** métrica escolhida e sua justificativa; tabela comparativa das métricas nos dois cenários; matrizes de confusão; análise dos erros (falsos positivos e falsos negativos — qual deles custa mais ao banco?).
6. **Discussão e conclusão:** qual modelo é o mais adequado e por quê; o que se aprendeu com a comparação entre os cenários; limitações; o que a dupla faria para melhorar os resultados.
7. **Declaração de uso de ferramentas de IA generativa:** se utilizadas, indicar em quais etapas e de que forma.

Critério	Peso	O que será observado
Análise exploratória	10%	Pertinência das visualizações e das conclusões extraídas; identificação das características da base que exigem tratamento ou influenciam a avaliação
Preparação dos dados	25%	Alterações na base corretas e justificadas; preparação que não compromete a validade da avaliação; identificação correta dos atributos excluídos no cenário principal
Modelagem	20%	Configuração correta dos três modelos; hiperparâmetros escolhidos por validação cruzada; variante de Naive Bayes justificada
Avaliação e comparação	25%	Escolha justificada da métrica principal; validação cruzada; comparação dos dois cenários; análise dos erros; interpretação dos coeficientes
Relatório	20%	Clareza, estrutura, norma culta, coerência entre notebook e texto